Informe de Proceso ETL – World Data

1. Proceso seguido

El trabajo consistió en la construcción de un pipeline **ETL (Extract, Transform, Load)** para la ingesta, normalización y validación de datos provenientes de múltiples **APIs públicas**:

- **RestCountries API** → información geográfica y cultural (países, continentes, capitales, fronteras, idiomas, monedas, husos horarios, gentilicios, índices GINI, imágenes, nombres alternativos, etc.).

- **World Bank API** → indicadores socioeconómicos y ambientales (población total, % población urbana, % población rural,, etc.).

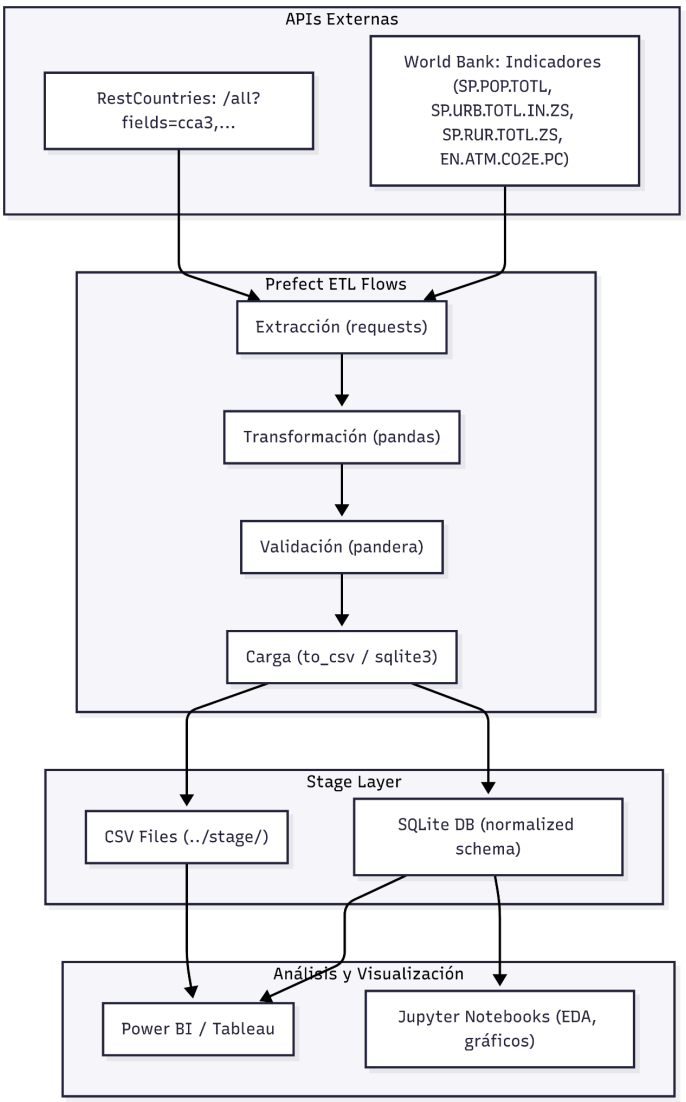

Extracción (Extract)

- Se definieron módulos ETL separados por entidad o indicador.
- Cada módulo consulta la API correspondiente y obtiene los datos en formato JSON o XML.
- Se agregó logging de progreso en la extracción paginada (World Bank), informando al usuario la página descargada y cantidad acumulada de filas.

Transformación (Transform)

- Normalización de estructuras anidadas y listas con **pandas** (`explode`, `apply`, `dict.items()`).
- Creación de claves foráneas lógicas (ej. país → idioma, país → frontera, país → indicador).
- Conversión de tipos de datos (años como enteros, porcentajes como floats).

Validaciones de integridad

- **Integridad relacional:** verificación de que los IDs de países usados en tablas de relación existan en la tabla principal.
- **Control de duplicados y nulos:** eliminación de filas inválidas.
- **Validaciones de formato con Pandera:**
    - Longitud de strings (ej. ISO 3 debe tener 3 caracteres).
    - Rango de valores numéricos (ej. latitudes -90 a 90, años >= 1900).
    - Existencia en conjuntos válidos (`Check.isin`).
    - URLs válidas en campos de imágenes.
    - Cohesión en indicadores (ej. año numérico, valores positivos donde corresponda).

Esto asegura consistencia y calidad de los datos antes de cargarlos en el *stage*.

Carga (Load)

- Los datos transformados se almacenan en **CSV** en el directorio `../stage/`.
- También se cargan en una base **SQLite**, creando tablas normalizadas y reemplazando datos en cada ejecución (`if_exists="replace"`).
- Esto asegura que cada corrida tenga datos actualizados e idempotentes.

Modelado y visualización

- Modelo en estrella con **países como tabla principal** y relaciones a dimensiones: idiomas, monedas, fronteras, husos horarios, indicadores socioeconómicos.
- Los datos enriquecidos permiten análisis combinados, por ejemplo:
    - Población total vs % urbana/rural.
    - Mapas de distribución por región.
- Compatible con herramientas de BI (Power BI, Tableau) y notebooks de exploración (EDA en Jupyter).

---

2. Herramientas y técnicas utilizadas

- **Lenguaje**: Python 3.13
- **Librerías principales**:
    - `requests` → extracción desde API.
    - `pandas` → transformación y limpieza.
    - `sqlite3` → carga en base relacional.
    - `prefect` → orquestación de los ETLs.
    - `pandera` → validación de esquemas.
    - `papermill / nbclient` → ejecución programática de notebooks.

Buenas prácticas aplicadas

- Modularización en **scripts ETL independientes**.
- Master Flow robusto:
  - Orquesta ejecución en orden lógico (primero países, último base de datos).
  - Detección automática de nuevos ETL (solo requiere colocarlos en el directorio con prefijo `etl_`).
- Validaciones de integridad y esquemas.
- Logs de ejecución detallados.
- Código limpio, comentado y extensible.

---

3. Consideraciones técnicas relevantes

Diseño flexible

- Transformaciones con estructuras dinámicas (`dict.items()`, `explode`) reducen dependencia de cambios en la API.
- El pipeline es fácilmente extensible a nuevos indicadores o APIs.

Automatización

- Prefect permite agendar y monitorear la ejecución.
- Flujos son idempotentes (no duplican información).

Limpieza e integridad

- Eliminación de valores nulos y duplicados.
- Control de claves foráneas simuladas.
- Validaciones de formatos de URLs y valores numéricos.

Extensibilidad

- La base SQLite puede migrar a **PostgreSQL, BigQuery o Snowflake** sin cambios en la lógica del ETL.

- Incorporación de nuevas fuentes externas (ej. indicadores económicos, ambientales, sanitarios).

- Posibilidad de agregar **procesamiento incremental** (solo datos nuevos o modificados).